



Data Science

Program Studi Informatika

Sesi 7 – Pengantar Machine Learning: Regresi Linear

Syahid Abdullah, S.Si, M.Kom



Outline



Pembukaan & Motivasi

Apa itu ML? Posisi regresi dalam AI: dari data ke prediksi



Lanskap Machine Learning

Supervised vs Unsupervised · Classification vs Regression · Algoritma umum



Regresi Linear

Persamaan, cost function MSE, gradient descent, simple vs multiple



Metrik Evaluasi Regresi

MAE, MSE, RMSE, R-Squared -> formula, interpretasi, kapan pakai apa



Machine Learning

Supervised · Unsupervised · Classification · Regression · Algoritma Lainnya



Supervised vs Unsupervised Learning

Supervised Learning

Model belajar dari pasangan (X, y) : data dengan label yang sudah diketahui.

Analogi: siswa belajar dari soal + kunci jawaban

Task:

Klasifikasi

Output = kelas/label

Contoh: spam/bukan spam, diagnosis penyakit

Regresi

Output = nilai kontinu

Contoh: harga rumah, gaji, suhu esok hari

Contoh Algoritma: Linear Regression, Decision Tree, SVM, Random Forest, Neural Network

Unsupervised Learning

Model mencari pola tersembunyi dari data tanpa label: tidak ada y yang diketahui.

Analogi: siswa belajar sendiri tanpa kunci jawaban -> temukan pola sendiri

Task:

Clustering

Kelompokkan data yang mirip

Contoh: segmentasi pelanggan, K-Means


Dimensionality Reduction

Reduksi fitur sambil mempertahankan informasi — PCA, t-SNE

Contoh Algoritma: K-Means, DBSCAN, PCA, Autoencoder, Hierarchical Clustering



Regresi Linear dalam Machine Learning



Jenis Algoritma Regresi:

Regresi Linear

Hubungan linear antara X dan y
Sederhana, interpretable

Regresi Polinomial

Kurva non-linear
 $y = \beta_0 + \beta_1x + \beta_2x^2$

Ridge / Lasso

Linear + regularisasi
Mengurangi overfitting

Random Forest Regression

Ensemble decision tree
Untuk hubungan non-linear kompleks



Regresi Linier


Persamaan · Cost Function · Gradient Descent · Simple & Multiple



Konsep Regresi Linier

Ide Dasar

Regresi linear mencari garis lurus terbaik yang mendeskripsikan hubungan antara variabel input (X) dan variabel output (y) yang bersifat kontinu.



Kapan digunakan:

- Target (y) berupa nilai kontinu — harga, gaji, suhu
- Hubungan antara X dan y bersifat linear
- Butuh model yang interpretable — koefisien mudah dijelaskan
- Baseline model sebelum mencoba algoritma lebih kompleks

Persamaan Regresi Linier

$$\hat{y} = \beta_0 + \beta_1 \cdot x$$

$\hat{y}$

Nilai yang diprediksi (y-hat)

β_0

Intercept: nilai y saat x = 0

β_1

Slope: seberapa banyak y berubah per unit x

x

Variabel input (fitur/prediktor)

Contoh:

$\hat{y} = 3.5 + 2.1 \cdot x \rightarrow$ gaji naik Rp 2,1 juta per tahun pengalaman




Cost Function

Residual: Selisih Prediksi vs Aktual

Untuk setiap titik data, residual (e_i) adalah selisih antara nilai aktual (y_i) dan nilai yang diprediksi model ($\hat{y}_i$):

$$e_i = y_i - \hat{y}_i$$




Fungsi Biaya (Cost Function): Mean Squared Error

$$MSE = \left(\frac{1}{n}\right) \cdot \sum (y_i - \hat{y}_i)^2$$

Mengapa dikuadratkan?

- Nilai negatif dan positif tidak saling menghapus
- Penalti lebih besar untuk kesalahan yang lebih besar (non-linear)
- Fungsi menjadi differentiable (bisa diturunkan) untuk optimasi

Tujuan: Minimumkan MSE





Gradient Descent

Algoritma Gradient Descent

Analogi: berjalan di pegunungan berkabut ingin menuruni Lembah, setiap langkah mengikuti arah turun tercuram.

1

Mulai dari titik acak

Inisialisasi β_0, β_1 secara acak

2

Hitung Gradient

Turunan MSE terhadap setiap β (arah naik terjal)

3

Update Parameter

$\beta := \beta - \alpha \cdot \nabla \text{MSE}$ (bergerak berlawanan arah gradient)

4

Ulangi hingga Konvergen

Iterasi sampai MSE tidak berubah signifikan

α (alpha) = Learning Rate: mengontrol ukuran langkah per iterasi

Update Rule

$$\beta_1 := \beta_1 - \alpha \cdot (\partial \text{MSE} / \partial \beta_1)$$

$$\beta_0 := \beta_0 - \alpha \cdot (\partial \text{MSE} / \partial \beta_0)$$

Dampak Pemilihan Learning Rate (α)

Terlalu Kecil

- ✓ Stabil, pasti konvergen
- ⚠ Sangat lambat, butuh banyak iterasi

Tepat

- ✓ Konvergen cepat & stabil
- ⚠ Perlu tuning, tidak ada nilai universal

Terlalu Besar

- ✓ Cepat di awal
- ⚠ Overshooting, MSE tidak konvergen



```
from sklearn.linear_model import LinearRegression
# scikit-learn menggunakan Ordinary Least Squares
# (solusi analitik tertutup, bukan iterasi GD)
model = LinearRegression()
model.fit(X_train, y_train)
#  $\beta_0$  = model.intercept_
#  $\beta_1$  = model.coef_[0]
```




Simple vs Multiple Linear Regression

Simple Linear Regression

$$\hat{y} = \beta_0 + \beta_1 x$$

Satu variabel input (X), satu output (y).



Contoh: Prediksi gaji dari lama pengalaman

Multiple Linear Regression

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Banyak variabel input, satu output.

Contoh fitur untuk prediksi harga rumah:

x_1	Luas bangunan (m²) <i>Semakin luas → harga naik</i>	+ positif
x_2	Jumlah kamar tidur <i>Lebih banyak → umumnya lebih mahal</i>	+ positif
x_3	Jarak ke pusat kota <i>Semakin dekat → lebih mahal</i>	± mixed
x_4	Usia bangunan <i>Lebih tua → cenderung lebih murah</i>	± mixed



```
model = LinearRegression()
model.fit(X_train, y_train)
print(model.coef_)    # [ $\beta_1$ ,  $\beta_2$ , ...,  $\beta_n$ ]
print(model.intercept_) #  $\beta_0$ 
```



Implementasi dengan Scikit-Learn

API Scikit-Learn

Semua estimator scikit-learn mengikuti pola yang sama: Instantiate → Fit → Predict → Evaluate.

`LinearRegression()`

Buat objek model dengan parameter default

`.fit(X_train, y_train)`

Latih model: menghitung β_0 dan β_1 optimal

`.predict(X_test)`

Prediksi nilai $\hat{y}$ untuk data baru

`.score(X_test, y_test)`

Hitung R^2 langsung

`.coef_`

Koefisien $\beta_1 \dots \beta_n$ (slope)

`.intercept_`

Intercept β_0



Implementasi dengan Scikit-Learn

```
import pandas as pd, numpy as np
import seaborn as sns
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import (mean_absolute_error,
                             mean_squared_error, r2_score)
import matplotlib.pyplot as plt

# — 1. Load Dataset —————
# Dataset: Experience vs Salary (sintetis)
np.random.seed(42)
n = 200
X = np.random.uniform(0, 15, n).reshape(-1, 1)
y = 3.5 + 2.1 * X.ravel() + np.random.normal(0, 1.5, n)

# — 2. Split —————
X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, random_state=42)

# — 3. Fit Model —————
model = LinearRegression()
model.fit(X_tr, y_tr)

print(f" $\beta_0$  (intercept): {model.intercept_:.3f}")
print(f" $\beta_1$  (slope) : {model.coef_[0]:.3f}")
#  $\beta_0 \approx 3.5$   $\beta_1 \approx 2.1$  (mendekati nilai true!)
```

```
# — 4. Predict & Evaluate —————
y_pred = model.predict(X_te)

mae = mean_absolute_error(y_te, y_pred)
rmse = mean_squared_error(y_te, y_pred, squared=False)
r2 = r2_score(y_te, y_pred)

print(f"MAE = {mae:.3f}")
print(f"RMSE = {rmse:.3f}")
print(f" $R^2$  = {r2:.3f}")

# — 5. Visualisasi —————
plt.scatter(X_te, y_te, alpha=0.6, label='Aktual')
plt.plot(X_te, y_pred, color='red', lw=2,
         label='Prediksi')
plt.xlabel('Pengalaman (tahun)')
plt.ylabel('Gaji (juta)')
plt.legend(); plt.show()
```



Metrik Evaluasi Algoritma Regresi

MAE · MSE · RMSE · R-Squared: Formula dan Interpretasi



MAE (Mean Absolute Error)

$$MAE = \left(\frac{1}{n}\right) \cdot \sum |y_i - \hat{y}_i|$$

Data Aktual (y)	55	60	80	40	70
Prediksi ($\hat{y}$)	50	65	75	45	68
Selisih e	5	5	5	5	2

$$MAE = (5+5+5+5+2) / 5 = 22/5 = 4.4$$

- ✓ Mudah diinterpretasi karena satuan sama dengan y
- ✓ Robust terhadap outlier -> penalti linear
- ⚠ Tidak differentiable di titik nol (optimasi lebih sulit)



```
from sklearn.metrics import mean_absolute_error
mae = mean_absolute_error(y_test, y_pred)
print(f"MAE = {mae:.3f}")
```



RMSE (Root Mean Squared Error)

$$RMSE = \sqrt{\left(\frac{1}{n}\right) \cdot \Sigma(y_i - \hat{y}_i)^2}$$

Hubungan MSE dan RMSE:

MSE = $(1/n) \cdot \Sigma(y_i - \hat{y}_i)^2$ ← kuadratkan dulu
RMSE = $\sqrt{MSE}$ ← ambil akar

- ✓ Satuan sama dengan y -> lebih intuitif dari MSE
- ✓ Penalti lebih besar untuk outlier dibanding MAE
- ⚠ Lebih sensitif terhadap outlier -> outlier besar sangat memengaruhi
- ✓ Paling umum digunakan dalam kompetisi ML (Kaggle, dll.)

RMSE lebih besar → MAE: perbedaan = pengaruh outlier

```
from sklearn.metrics import mean_squared_error
mse = mean_squared_error(y_test, y_pred)
rmse = mean_squared_error(y_test, y_pred,
                          squared=False) # RMSE langsung
# atau: rmse = np.sqrt(mse)
print(f"MSE = {mse:.3f}")
print(f"RMSE = {rmse:.3f}")
```



R-Squared (R^2): Koefisien Determinasi


$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} \quad ; \quad SS_{res} = \sum (y_i - \hat{y}_i)^2 \quad SS_{tot} = \sum (y_i - \bar{y})^2$$

Model Buruk ($R^2 \approx 0.05$)



→ Garis hampir datar: model gagal menjelaskan variasi data

Model Baik ($R^2 \approx 0.92$)



→ Garis mengikuti pola: model menjelaskan 92% variasi data

Interpretasi R^2

< 0.3

Lemah: Model hampir tidak menjelaskan data

0.3–0.6

Sedang: Model cukup, bisa diperbaiki

0.6–0.8

Baik: Model menjelaskan mayoritas variasi


> 0.8

Sangat Baik: Model sangat fit, waspadai overfitting



Perbandingan Metrik

RMSE dua model di 3 proyek (lebih kecil = lebih baik)



Cara Membaca RMSE

RMSE = 2.1 juta rupiah berarti model rata-rata meleset sekitar Rp 2,1 juta dari harga aktual — apakah itu besar atau kecil tergantung konteks (harga rata-rata Rp 300 juta $\rightarrow$ RMSE < 1% = sangat baik).

RMSE harus diinterpretasikan relatif terhadap skala y, bukan secara absolut.



Tabel Perbandingan Metrik Regresi

Metrik	Formula	Keunggulan	Kelemahan	Gunakan saat
MAE	Rata-rata $ \text{error} $	Satuan sama dengan y; robust outlier	Tidak memberi penalti besar untuk outlier ekstrem	Jika outlier tidak penting dan interpretabilitas utama
MSE	Rata-rata error^2	Differentiable -> baik untuk optimasi	Satuan dikuadratkan (sulit diinterpretasi)	Internal training / loss function
RMSE	$\sqrt{\text{MSE}}$	Satuan sama dengan y; penalti outlier besar	Sensitif outlier -> satu outlier bisa mendominasi	Reporting & benchmarking, paling umum digunakan
R²	$1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}}$	Skala universal 0–1, mudah dibandingkan	Bisa menyesatkan jika baseline model sangat buruk	Menjelaskan % variasi yang dijelaskan model



Aktivitas Hands-on

Lakukan aktivitas sesuai Panduan yang tertera pada Modul Pembelajaran 6



Terima Kasih